

Rapport hors séance - TP1

Page de garde

- **Module** : Linked Open Data
- **TP** : TP1 - Introduction aux données ouvertes liées
- **Groupe** : EL AKKIOUI & BELLIL
- **Étudiants** : Aymane EL AKKIOUI & Zakaria BELLIL
- **Date** : 19 Avril 2026

1. Introduction

Ce rapport présente l'étude préparatoire à la sémantisation du jeu de données des établissements de l'enseignement supérieur universitaire public au Maroc (2024-2025). L'enjeu de ce travail est de transformer une ressource Open Data tabulaire (niveau 3 étoiles) en un graphe de connaissances interconnecté (LOD). Nous étudions ici les mécanismes d'identification unique et d'alignement sémantique nécessaires pour garantir l'interopérabilité des données académiques marocaines avec le Web de données mondial.

2. Types d'entités étudiés

Nous avons retenu trois types d'entités piliers pour cette étude :

1. **Établissement (Institution)** : C'est l'unité centrale du dataset. L'objectif est de passer d'un simple nom textuel à une ressource identifiable par une URI.
2. **Ville (City)** : Entité géographique permettant de lier les établissements à des référentiels spatiaux mondiaux.
3. **Domaine disciplinaire (Field)** : Concept thématique (ex: Informatique, Sciences) permettant de regrouper les établissements par spécialité via des thésaurus standardisés.

Ces choix reposent sur la présence de champs pivots dans le dataset (`institution_name`, `city`, `main_field`) qui facilitent l'appariement externe.

3. Benchmark des référentiels externes

Nous avons comparé deux référentiels majeurs pour l'alignement :

Critère	Wikidata	GeoNames
Couverture	Excellente pour les universités et grandes écoles (ENSIAS, EMI).	Exhaustive pour les villes marocaines.
Précision sémantique	Très haute (distinction entre université et faculté).	Limitée aux aspects administratifs et spatiaux.
Identifiants	Stables (Q-nodes), résolvables en RDF.	Stables (IDs numériques), très utilisés en géomatique.
Richesse sémantique	Liens vers les directeurs, les dates de création et les coordonnées.	Hierarchie administrative (Région, Province).

Conclusion du benchmark : Wikidata sera notre pivot institutionnel, tandis que GeoNames servira de référentiel d'autorité pour la spatialisation des données.

4. Cas d'appariement manuel

Entité locale	Type	Référentiel cible	Correspondance candidate	Indices utilisés	Confiance	Décision
ENSIAS	Établissement	Wikidata	Q3577884	Nom + Ville + Tutelle UM5	Élevée	Accepté
Univ. Mohammed V	Établissement	Wikidata	Q1541823	Nom exact	Élevée	Accepté
Rabat	Ville	GeoNames	2538475	Nom + Pays Maroc	Élevée	Accepté
Fac. Sciences Rabat	Établissement	Wikidata	Q3064434	Nom + Ville	Élevée	Accepté
Computer Science	Domaine	Wikidata	Q21198	Sens sémantique	Moyenne	Accepté
EMI	Établissement	Wikidata	Q3578278	Acronyme + Rabat	Élevée	Accepté

5. Plan de normalisation et d'identification

Normalisation des valeurs

- **Nettoyage textuel** : Suppression des espaces doubles, uniformisation de la casse (**trim** et **lowercase**) et suppression des caractères spéciaux pour les noms d'établissements.
- **Toponymie** : Correction des variantes orthographiques des villes (ex: "Fes" vers "Fès") pour correspondre au label préféré des référentiels.

Stratégie d'identification

Nous proposons de construire des URIs persistantes sur l'espace de noms suivant :

<http://data.gov.ma/resource/education/>

Les règles de construction seront :

- **Établissements** : `{base_uri}institution/{slug(short_name)}-{slug(city)}`
- **Villes** : Utilisation directe de l'URI GeoNames pour éviter la duplication (<https://sws.geonames.org/{id}/>).

6. Analyse des risques

1. **Faux appariements** : Risque élevé sur les acronymes partagés (ex: ENSA présent dans plusieurs villes). La règle d'appariement doit impérativement être composite (Nom + Ville).
2. **Désambiguïsation** : Certaines facultés ont changé de nom ou de tutelle (fusions d'universités). L'alignement doit vérifier la propriété "part of" ([P361](#) sur Wikidata).
3. **Limites des référentiels** : Certains petits instituts ou annexes ne possèdent pas encore d'entrée Wikidata, ce qui créera des nœuds isolés (graphe "troué").

7. Difficultés rencontrées

- **Absence de codes officiels** : Le dataset ne contient pas de code unique ministériel (type code Apogée), nous obligeant à forger des identifiants basés sur des libellés textuels instables.
- **Qualité des chaînes** : La présence ou l'absence d'accents dans le fichier source crée des désaccords lors de l'utilisation d'algorithmes de réconciliation automatique.
- **Domaines académiques** : Le champ `main_field` est trop générique, rendant l'alignement sur des concepts précis (ex: "Sciences" vs "Physique-Chimie") parfois arbitraire.

8. Conclusion

Cette étude préparatoire démontre que le jeu de données du MESRSI possède un fort potentiel de liaison, particulièrement grâce à la richesse de Wikidata sur le milieu académique marocain. La définition d'un plan de normalisation rigoureux et d'une nomenclature d'URIs stable est l'étape critique franchie ici. Ce travail facilite directement le TP2 en fournissant les règles de transformation nécessaires à l'écriture des scripts de conversion RDF.

Annexes éventuelles

Schéma conceptuel du graphe cible



